Regras de Associação Apriori

Heitor Gabriel S. Monteiro

08/11/2021

Contents

1 Prelúdio
2 Importação e Descrição dos Dados
3 O Modelo
5

1 Prelúdio

Nosso objetivo é entender possíveis associações entre itens na cesta de consumo de uma base de dados de compras no supermercado. Para tal, usaremos o algoritmo *Apriori* que tem alguns conceitos chaves:

• Support(A):

$$=\frac{Freq(A)}{N}=P(A)$$

• Support(A,B):

$$=\frac{Freq(A \wedge B)}{N} = P(A \cap B)$$

• Confidence(A \rightarrow B):

$$=\frac{Supp(A,B)}{Supp(A)}=\frac{Freq(A \wedge B)}{Freq(A)}=\frac{P(A \cap B)}{P(A)}=P(B|A)$$

• Lift(A \rightarrow B):

$$= Lift(B \to A) = \frac{Conf(A \to B)}{Supp(A)Supp(B)} = \frac{P(A \cap B)}{P(A)P(B)}$$

Aplicando-os em nossa situação, *Support* é a probabilidade de encontrar o produto A numa cesta de compras, ou uma sub-cesta (A, B) na cesta. *Confidence* é a chance de encontrar o produto B se já encontramos o A, a frequência do B em todas as compras que contenham A. *Lift* mede a chance de um conjunto (A, B) aparecer juntos comparado à chance de suas frequências absolutas. Se, por exemplo, Lift(A, B) > 1, então há mais chances de ver os produtos A e B juntos do que encontrar A ou B, sozinho.

2 Importação e Descrição dos Dados

Vamos definir o diretório de trabalho, que contém os arquivos e guardará as saídas, e carregar os pacotes, com destaque para o arules e o arules Viz.

```
setwd('/home/heitor/Área de Trabalho/R Projects/Análise Macro/Labs/Lab 11')
library(tidyverse)
library(arules)
library(arulesViz)
library(RColorBrewer)
library(knitr)
library(kableExtra)
```

O tipo otimizador de lidar com esse banco é trabalhar como arquivo de transações, usaremos então o read.transactions(). Na visão geral, vemos 9.835 transações com 169 categorias de produtos; o tamanho médio das compras são 4,4 produtos.

```
dds <- read.transactions("groceries.csv", sep = ",")</pre>
summary(dds)
## transactions as itemMatrix in sparse format with
##
    9835 rows (elements/itemsets/transactions) and
    169 columns (items) and a density of 0.02609146
##
## most frequent items:
##
         whole milk other vegetables
                                              rolls/buns
                                                                      soda
##
                2513
                                  1903
                                                    1809
                                                                      1715
##
             yogurt
                               (Other)
                                 34055
##
                1372
##
## element (itemset/transaction) length distribution:
## sizes
##
      1
                 3
                            5
                                      7
                                            8
                                                                12
                                                                     13
                                                                           14
                                                                                15
                                 6
                                                     10
                                                           11
## 2159 1643 1299 1005
                        855
                              645
                                    545
                                        438
                                               350
                                                    246
                                                         182
                                                                     78
```

16

46

```
24
                                                                     32
##
     17
          18
                19
                     20
                          21
                                22
                                     23
                                                26
                                                     27
                                                           28
                                                                29
##
     29
                      9
                          11
                                 4
                                      6
                                           1
                                                 1
                                                      1
                                                            1
                                                                 3
                                                                      1
          14
                14
##
##
      Min. 1st Qu. Median
                                Mean 3rd Qu.
                                                 Max.
                                               32.000
##
     1.000
             2.000
                      3.000
                               4.409
                                       6.000
##
## includes extended item information - examples:
                labels
##
## 1 abrasive cleaner
## 2 artif. sweetener
       baby cosmetics
inspect(dds[1:5])
##
       items
## [1] {citrus fruit,
##
        margarine,
##
        ready soups,
##
        semi-finished bread}
## [2] {coffee,
        tropical fruit,
##
##
        yogurt}
## [3] {whole milk}
## [4] {cream cheese,
##
        meat spreads,
##
        pip fruit,
##
        yogurt}
## [5] {condensed milk,
##
        long life bakery product,
##
        other vegetables,
##
        whole milk}
Podemos ver o support de cada item. Também fiz as seguintes operações para conseguir
observar o support por pesquisa, no caso, pesquisei ine:
itemFrequency(dds[,1:3])
## abrasive cleaner artif. sweetener
                                         baby cosmetics
       0.0035587189
                                            0.0006100661
##
                         0.0032536858
```

tst <- itemFrequency(dds) %>%
 as.data.frame() %>%


rownames_to_column(var='product')

Table 1: Products that have 'ine' in name.

product	frq
margarine	0.0585663
red/blush wine	0.0192171
sparkling wine	0.0055923
vinegar	0.0065074
white wine	0.0190137

Com o programa, podemos fazer o plot dos mais frequentes produtos comprados:

Absolute Item Frequency Plot



3 O Modelo

Precisamos definir o modelo d acordo com os mínimos support, confidence, e minlen, que é o tamanho mínimo da cesta comprada. Considerando que as transações são de um período de um mês, determinei que a frequência seja de duas compras e meia por dia, daí o (2.5*30)/9835. Média de suporte e confidência não próximos do fixado é um indicativo que não escolhemos valores muito grandes ao ponto de prejudicar-nos.

```
rule1 <- apriori(dds, parameter=
                                    = (2.5*30)/9835,
                    list(support
                         confidence = 0.25,
                         minlen = 2)
## Apriori
##
## Parameter specification:
## confidence minval smax arem aval originalSupport maxtime
                                                                   support minlen
          0.25
                  0.1
                         1 none FALSE
                                                 TRUE
                                                             5 0.007625826
##
##
   maxlen target ext
        10 rules TRUE
##
##
## Algorithmic control:
## filter tree heap memopt load sort verbose
       0.1 TRUE TRUE FALSE TRUE
##
                                         TRUE
## Absolute minimum support count: 75
##
## set item appearances ...[0 item(s)] done [0.00s].
## set transactions ...[169 item(s), 9835 transaction(s)] done [0.01s].
## sorting and recoding items ... [102 item(s)] done [0.00s].
## creating transaction tree ... done [0.01s].
## checking subsets of size 1 2 3 4 done [0.00s].
## writing ... [318 rule(s)] done [0.00s].
## creating S4 object ... done [0.00s].
rule1
## set of 318 rules
rule1 %>% summary()
## set of 318 rules
```

```
##
## rule length distribution (lhs + rhs):sizes
##
     2
         3
             4
## 124 186
             8
##
##
      Min. 1st Qu.
                    Median
                               Mean 3rd Qu.
                                               Max.
##
     2.000
             2.000
                     3.000
                              2.635
                                      3.000
                                               4.000
##
## summary of quality measures:
##
                          confidence
                                                                 lift
       support
                                            coverage
##
   Min.
           :0.007626
                       Min.
                               :0.2513
                                         Min.
                                                 :0.01230
                                                            Min.
                                                                   :0.9932
##
    1st Qu.:0.008643
                       1st Qu.:0.2975
                                         1st Qu.:0.02298
                                                            1st Qu.:1.6078
##
   Median : 0.010269
                       Median :0.3602
                                         Median : 0.03010
                                                            Median :1.8968
##
                               :0.3760
   Mean
           :0.013760
                       Mean
                                         Mean
                                                 :0.03896
                                                            Mean
                                                                   :1.9903
                        3rd Qu.:0.4442
                                                            3rd Qu.:2.3248
    3rd Qu.:0.014718
                                         3rd Qu.:0.04342
##
   Max.
           :0.074835
                               :0.6389
                                                 :0.25552
                                                                   :3.7969
                       Max.
                                         Max.
                                                            Max.
##
        count
          : 75.0
##
   Min.
    1st Qu.: 85.0
   Median :101.0
##
##
           :135.3
   Mean
##
    3rd Qu.:144.8
##
   Max.
           :736.0
##
## mining info:
    data ntransactions
##
                            support confidence
##
     dds
                  9835 0.007625826
                                          0.25
```

Podemos ver quais são as regras de associação descobertas, organizadas por pesquisa ou por ranqueamentos:

```
inspect(rule1[1:3])
```

```
##
       lhs
                      rhs
                                          support
                                                      confidence coverage
## [1] {herbs}
                   => {other vegetables} 0.007727504 0.4750000 0.01626843
## [2] {herbs}
                   => {whole milk}
                                          0.007727504 0.4750000
                                                                 0.01626843
## [3] {detergent} => {whole milk}
                                          0.008947636 0.4656085
                                                                 0.01921708
##
       lift
                count
## [1] 2.454874 76
## [2] 1.858983 76
## [3] 1.822228 88
```

```
# procurando por regras que contenham "yoqurt"
inspect(
    subset(rule1, items %pin% "yogurt")[1:10]) %>%
    as.data.frame() %>%
    kable(caption = "Rules that have 'yogurt' in name.") %>%
 kable_styling(full_width =F,
              position = 'center',
              bootstrap_options =
                c("striped", "hover",
                  "condensed", "responsive"))
                                                         confidence coverage
##
        lhs
                                             support
                                   rhs
## [1]
        {butter milk}
                                => {yogurt} 0.008540925 0.3054545
                                                                    0.02796136
## [2]
                                => {yogurt} 0.008032537 0.3278008
       {sliced cheese}
                                                                    0.02450432
## [3]
       {berries}
                                => {yogurt} 0.010574479 0.3180428
                                                                    0.03324860
## [4]
                                => {yogurt} 0.009862735 0.2657534
       {dessert}
                                                                    0.03711235
## [5]
       {cream cheese}
                                => {yogurt} 0.012404677 0.3128205 0.03965430
                                => {yogurt} 0.012404677 0.2579281
## [6]
       {frozen vegetables}
                                                                    0.04809354
```

```
=> {yogurt} 0.017285206 0.3244275
## [7]
       {curd}
                                                                    0.05327911
## [8]
        {butter}
                                => {yogurt} 0.014641586 0.2642202
                                                                    0.05541434
        {fruit/vegetable juice} => {yogurt} 0.018708693 0.2587904
## [9]
                                                                    0.07229283
## [10] {whipped/sour cream}
                                => {yogurt} 0.020742247 0.2893617
                                                                    0.07168277
##
        lift
                 count
## [1]
       2.189610 84
## [2]
       2.349797
                  79
## [3]
       2.279848 104
## [4]
       1.905018 97
## [5]
        2.242412 122
       1.848924 122
## [6]
## [7]
       2.325615 170
## [8]
        1.894027 144
```

```
# organizando por uma característica específica
inspect(sort(rule1, by = "count")[1:5])
```

[9]

1.855105 184

[10] 2.074251 204


```
## | 1hs | rhs | support | confidence | coverage | rhs | | confidence | coverage | rhs | | confidence | coverage | confidence | coverage | rhs | | confidence | coverage |
```

Table 2: Rules that have 'yogurt' in name.

	lhs		rhs	support	confidence	coverage	lift	count
[1]	{butter milk}	=>	{yogurt}	0.0085409	0.3054545	0.0279614	2.189610	84
[2]	{sliced cheese}	=>	{yogurt}	0.0080325	0.3278008	0.0245043	2.349797	79
[3]	{berries}	=>	{yogurt}	0.0105745	0.3180428	0.0332486	2.279848	104
[4]	{dessert}	=>	{yogurt}	0.0098627	0.2657534	0.0371124	1.905018	97
[5]	{cream cheese}	=>	{yogurt}	0.0124047	0.3128205	0.0396543	2.242412	122
[6]	{frozen vegetables}	=>	{yogurt}	0.0124047	0.2579281	0.0480935	1.848923	122
[7]	{curd}	=>	{yogurt}	0.0172852	0.3244275	0.0532791	2.325615	170
[8]	{butter}	=>	{yogurt}	0.0146416	0.2642202	0.0554143	1.894027	144
[9]	{fruit/vegetable juice}	=>	{yogurt}	0.0187087	0.2587904	0.0722928	1.855105	184
[10]	{whipped/sour cream}	=>	{yogurt}	0.0207422	0.2893617	0.0716828	2.074251	204


Para vizualização, podemos fazer um refinamento maior ainda, para ficar com as maiores *confidence*, acima de 0.5. A visualização mostra que

```
sub_rule1 <- rule1[quality(rule1)$confidence>0.5]
plot(sub_rule1)
```




```
plot(sub_rule1,
    method="paracoord",
    control=list(alpha=.5, reorder=TRUE))
```

Parallel coordinates plot for 37 rules



```
plot(sub_rule1,
    method = "grouped", control = list(k = 5))
```



```
method="graph", control=list(type="items"))

## Available control parameters (with default values):
## layout = list(fun = function (graph, dim = 2, ...) { if ("layout" %in% graph ## edges = <environment>
## nodes = <environment>
## nodetext = <environment>
```

max = 100

= ggplot2

colors ## engine = c("#EE0000FF", "#EEEEEFF")

